RAPPORT DE PROJET EN TECHNIQUES DÆ COMPILATION

Fait par:
IMLOUL Fatima Zahrae
EL HADRAOUI Oumaima

Titre du Projet :

Analyse de Séquences à l'aide de Grammaire EBNF

Plan

Résumé	3
ntroduction	3
Contexte Théorique	3
Conception et Méthodologique	3
1. Analyseur lexical (Lexer)	3
2. Analyseur syntaxique (Parser)	7
-Les règles de la grammaire EBNF avec leurs aut	omates
associés	7
-Analyse lexicale avec le Lexer	19
-Analyse syntaxique avec le Parser	20
Conclusion	21

Résumé:

Le projet vise à développer un programme **d'analyse de séquences** en utilisant la grammaire sous forme de règles **EBNF**. En appliquant ces règles, le programme sera capable d'effectuer **une analyse syntaxique** des séquences en entrée, contribuant ainsi à la compréhension des principes fondamentaux de la compilation.

Introduction:

L'analyse syntaxique est une étape cruciale dans le processus de compilation, permettant de vérifier la structure grammaticale d'un programme. Ce projet se concentre sur l'utilisation de **la grammaire EBNF** pour décrire formellement **la syntaxe des séquences**. Le développement d'un programme dédié à cette tâche contribuera à renforcer les connaissances pratiques dans le domaine de la compilation.

Contexte Théorique :

La **grammaire EBNF** est une extension de la notation de **B**ackus-**N**aur, largement utilisée pour décrire la syntaxe des langages de programmation. Elle utilise des règles de production pour spécifier les constructions grammaticales autorisées. **L'analyse syntaxique** consiste à déterminer si une séquence de **tokens** suit les règles définies par la grammaire.

Conception et Méthodologie

1. Analyseur lexical (Lexer):


Définitions des tokens et des expressions régulières :

On a défini des tokens tels que **IF**, **TYPE**, **ASSIGN**,..., avec des expressions régulières correspondantes. Ces dernières couvrent divers éléments, y compris les opérations arithmétiques, les opérateurs de comparaison, les mots-clés, ...


```
🕏 FinalProject.py > ...
                                    FinalProject.py > ...
 1 ∨ import sys
      import ply.lex as lex
                                                'SEMICOLON',
      import ply.yacc as yacc
                                               'COMMENT',
 5 ∨ tokens = [
                                               'WHILE',
          'INTEGER',
                                           t_IF = r'if'
                                           t_TYPE = r'\b(?:bool|string|float|int)\b'
                                           t_ASSIGN = r'='
                                           t_BOOLEAN = r'\b(?:true|false)\b'
                                           t_STRING = r'\"([^\\\n]|(\\.))*?\"'
                                           t_FLOAT = r'\d+\.\d+'
          'LEQ',
                                           t_INTEGER = r'\d+'
                                           t_THEN = r'then'
          'EQ',
                                           t_ELSE = r'else
          'LPAREN',
                                           t_PLUS = r' +'
                                           t_MINUS = r'-'
                                           t_TIMES = r'\*'
                                           t_DIVIDE = r'/'
                                           t_LT = r'<'
          'SEMICOLON'
```

```
FinalProject.py > ...
        t_BOOLEAN = r'\b(?:true|false)\b'
        t_STRING = r'\"([^\\\n]|(\\.))*?\"'
        t_FLOAT = r'\d+\.\d+'
        t_INTEGER = r'\d+'
        t_THEN = r'then'
        t_ELSE = r'else'
        t_PLUS = r' +'
        t_MINUS = r'-'
        t_TIMES = r'\*'
        t_DIVIDE = r'/'
        t_LT = r' < '
        t_GT = r'>'
        t_LEQ = r'<='
        t_GEQ = r'>='
        t_EQ = r'=='
        t_LACCO = r'{'
        t_RACCO = r'}'
        t_DIFFERENT = r'!='
        t_{AND} = r'&&'
        t_LPAREN = r'\('
        t_RPAREN = r'\)'
        t_NOT = r'!'
        t_SEMICOLON = r';'
        t_VIRGULE = r','
        t_COMMENT = r'\/\/.*'
        t_PRINT = r'print'
        t_SCAN = r'scan'
        t_WHILE = r'while'
        t_D0 = r'do'
      t_FOR=r'for'
      t_IDENT = r'(?!if|else|while|do|for|then|int|float|string|print|scan)[a-zA-Z_][a-zA-Z0-9_]*
Voici quelques tokens avec leurs automates :
IF = " if "
THEN = "then"
ELSE = "else"
```

```
IF = " if "
THEN = "then"
ELSE = "else"
WHILE = "while"
TYPE = "bool" | "string" | "float" | "int"
ASSIGN = " = "
BOOLEAN = "true" | "false"
FLOAT = chiffre {chiffre} ". " chiffre {chiffre}
```



INTEGER = chiffre {chiffre}



```
Chiffre=0|1|2|3|4|5|6|7|8|9
PLUS = "+"
AND = "&& "
LPAREN = "("
RPAREN = ")"
VIRGULE = ","
MINUS = "-"
TIMES = "*"
DIVIDE = "/"
LT = "< "
GT = ">"
NOT = "!"
PRINT = "print"
```

DO = "do"
FOR = "for"
LEQ = "=< "
GEQ = "> "
EQ = "== "
LACCO = "{ "

RACC = "}"

DIFFERENT = "!= " SEMICOLON = ", "

IDENT = *lettre {lettre | chiffre | _ }

lettre = a | b | | z | A | | Z

```
tignore = '\t'

tignore = '\t'

frack line numbers and positions

lexer_line_start = 1

texer_pos_in_line = 1

fr'\n+'

fr'\n+'

lexer_lineno += len(t.value)

global lexer_line_start, lexer_pos_in_line

lexer_line_start = t.lexer.lineno

lexer_line_start = t.lexer.lineno

lexer_pos_in_line = 1

def t_error(t):

global lexer_pos_in_line

print("")

float lexer_pos_in_line

print(frereur lexicale: lexeme non reconnu par l'analyseur lexical '\t.value[0]\t' at line \tanlor

print(frereur lexicale: lexeme non reconnu par l'analyseur lexical '\t.value[0]\t' at line \tanlor

t.lexer_skip(1)

sys.exit(1)

float

lea

lea

lea

lea

float

fl
```

Caractères Ignorés : Les espaces et les tabulations sont ignorés (t_ignore = '\t').

Gestion des Nouvelles Lignes : La fonction t_newline est définie pour suivre les numéros de ligne lors de la rencontre de caractères de nouvelle ligne. Gestion des erreurs lexicales : La fonction t_error est définie pour afficher un message d'erreur pour les caractères illégaux.


2. Analyseur syntaxique (Parser):

Règles de grammaire :


- Définition **des règles de grammaire** pour différentes constructions syntaxiques, telles que les déclarations, les instructions conditionnelles, les boucles, etc.
- Les règles sont écrites dans un format proche des productions **EBNF**, facilitant la compréhension.

Les règles avec leurs automates associés


Bloc = [DeclarationList] Bloc_Instruction




DeclarationList = Declaration SEMICOLON {DeclarationList}



Declaration = TYPE IDENT { VIRGULE IDENT } [Affectation1]




Affectation1 = ASSIGN (BOOLEAN | STRING | FLOAT | INTEGER)




Bloc_Instruction = [Instruction1 SEMICOLON [Bloc_Instruction] | Instruction2 [Bloc_Instruction]]


```
def p_bloc_instruction(p):
    '''Bloc_Instruction : Instruction1 SEMICOLON Bloc_Instruction
                          Instruction2 Bloc_Instruction
                          Instruction1 SEMICOLON
                          Instruction2
                         Empty'''
    if len(p) == 4:
        p[0] = (p[1], p[2], p[3])
   elif len(p) == 3:
        p[0] = (p[1], p[2])
    else:
        p[0] = p[1]
```




Instruction1 = Lecture | Ecriture | Affectation2



Instruction2 = Instruction_Conditionnelle | Instruction_Repetition_While | Instruction_Repetition+For | DeclarationList | COMMENT




Instruction_Repetition_While = WHILE LPAREN Expression RPAREN DO LACCO Bloc Instruction RACCO



Instruction_Repetition_For = FOR LPAREN [TYPE] IDENT Affectation1
SEMICOLON IDENT (GT | LEQ | LT | GEQ | DIFFERENT | EQ)
Expression_Simple SEMICOLON Affectation2 RPAREN (LACCO
Bloc_Instruction RACCO | Bloc_Instruction)

```
| FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT DIFFERENT Expression_Simple SEMICOLON Affectation2 RPAREN
LACCO Bloc_Instruction RACCO
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT EQ Expression_Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc_Instruction RACCO
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT LT Expression_Simple SEMICOLON Affectation2
RPAREN Bloc Instruction
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT GT Expression_Simple SEMICOLON Affectation2
RPAREN Bloc Instruction
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT LEQ Expression_Simple SEMICOLON Affectation2 RPAREN
Bloc_Instruction
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT GEQ Expression_Simple SEMICOLON Affectation2 RPAREN
Bloc_Instruction
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT DIFFERENT Expression_Simple SEMICOLON Affectation2 RPAREN
Bloc_Instruction
                                  | FOR LPAREN TYPE IDENT Affectation1
SEMICOLON IDENT EQ Expression Simple SEMICOLON Affectation2 RPAREN
Bloc_Instruction
                                  FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT LT Expression_Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc_Instruction RACCO
                                  FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT GT Expression_Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc_Instruction RACCO
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT LEQ Expression Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc Instruction RACCO
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT GEQ Expression Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc Instruction RACCO
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT DIFFERENT Expression_Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc Instruction RACCO
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT EQ Expression_Simple SEMICOLON Affectation2 RPAREN LACCO
Bloc Instruction RACCO
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT LT Expression_Simple SEMICOLON Affectation2 RPAREN Bloc_Instruction
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT GT Expression Simple SEMICOLON Affectation2 RPAREN Bloc Instruction
                                  | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT LEQ Expression_Simple SEMICOLON Affectation2 RPAREN Bloc Instruction
```

```
FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT GEQ Expression_Simple SEMICOLON Affectation2 RPAREN Bloc_Instruction
                                   | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT DIFFERENT Expression_Simple SEMICOLON Affectation2 RPAREN
Bloc_Instruction
                                   | FOR LPAREN IDENT Affectation1 SEMICOLON
IDENT EQ Expression_Simple SEMICOLON Affectation2 RPAREN Bloc_Instruction'''
    if len(p) == 15:
        p[0] = (p[1], p[2],
p[3],p[4],p[5],p[6],p[7],p[8],p[9],p[10],p[11],p[12],p[13],p[14])
    elif len(p) == 14:
        p[0] = (p[1], p[2],
p[3],p[4],p[5],p[6],p[7],p[8],p[9],p[10],p[11],p[12],p[13])
    elif len(p) == 13:
        p[0] = (p[1], p[2],
p[3],p[4],p[5],p[6],p[7],p[8],p[9],p[10],p[11],p[12])
        p[0] = (p[1], p[2], p[3], p[4], p[5], p[6], p[7], p[8], p[9], p[10], p[11])
```



Instruction_Conditionnelle = IF LPAREN Expression RPAREN THEN (LACCO Bloc Instruction RACCO | Bloc Instruction)]

```
p_instruction_conditionnelle(p)
 ''Instruction_Conditionnelle : IF LPAREN Expression RPAREN THEN LACCO Bloc_Instruction RACCO ELSE LACCO Bloc_Instruction RACCO
                               IF LPAREN Expression RPAREN THEN LACCO Bloc_Instruction RACCO ELSE Bloc_Instruction
                              | IF LPAREN Expression RPAREN THEN Bloc_Instruction'
if len(p) == 7:
   p[0] = (p[1], p[2], p[3], p[4], p[5],p[6])
   p[0] = (p[1], p[2], p[3], p[4], p[5], p[6], p[7],p[8])
                                     LPAREN
                                                                                RPAREN
                                                                                             4
                                                                                      THEN
                  ELSE
                                                                                 LACCO
       9
                            8
                                                  7
                                                                       6
          LACCO
      10
                            11
                                                 12
```

Affectation2 = IDENT ASSIGN Expression

(13)


Bloc Instruction

```
def p_affectation2(p):
    '''Affectation2 : IDENT ASSIGN Expression'''
    p[0] = (p[1], p[2], p[3])
```




Lecture = PRINT LPAREN Expression RPAREN

```
def p_lecture(p):
    '''Lecture : PRINT LPAREN Expression RPAREN'''
    p[0] = (p[1], p[2], p[3], p[4])
```




Ecriture = SCAN LPAREN Valeur RPAREN


```
def p_ecriture(p):
    '''Ecriture : SCAN LPAREN Valeur RPAREN'''
    p[0] = (p[1], p[2], p[3], p[4])
```



Valeur = Entree { VIRGULE Entree }





Entree = STRING | BOOLEAN | FLOAT | INTEGER



Expression = Expression_Simple [OperateurComparaison Expression_Simple]


OperateurComparaison = LT | GT | GEQ | EQ | DIFFERENT | AND






Expression_Simple = [Signe] Terme { OperateurAddSous Terme }

XXXXXXX




Signe = PLUS | MINUS

OperateurAddSous = PLUS | MINUS




Terme = Facteur { OperateurMulDiv Facteur }




17


OperateurMulDiv = TIMES | DIVIDE





Facteur = LPAREN Expression RPAREN | NOT Facteur | IDENT | BOOLEAN | INTEGER | STRING | FLOAT





Empty = E

`p_empty` est une règle de la grammaire qui représente une séquence vide. Lorsqu'elle est utilisée, elle ne génère rien (`pass`). En d'autres termes, elle indique qu'une partie de la syntaxe peut être absente.

```
def p_empty(p):
    'Empty :'
    pass
```

Gestion des erreurs syntaxiques : La fonction `p_error` est une règle spéciale appelée en cas d'erreur syntaxique. Elle affiche un message détaillé sur l'erreur (ligne, position, type de token) et termine le programme avec `sys.exit(1)`.

```
# Error rule for syntax errors

def p_error(p):
    if p:
        print(f"Syntax error at line {p.lineno}, pos {p.lexpos}: Unexpected token '{p.value}' in rule '{p.type}'")
        print(" ")
        print("La sequence d'instructions est syntaxiquement incorrecte")
        print("Les instructions ne sont pas reconnus par le PARSER")
        print(" ")
        sys.exit(1)
    else:
        print("Syntax error: Unexpected end of input")
        print(" ")
        print("La sequence d'instructions est syntaxiquement incorrecte")
        print("Les instructions ne sont pas reconnus par le PARSER")
        print("Les instructions ne sont pas reconnus par le PARSER")
        sys.exit(1)
```

Analyse lexicale avec le Lexer :

Cette partie utilise l'analyseur lexical (`lexer`) pour découper le code source (`data`) en tokens. Chaque token est ensuite imprimé avec des informations sur sa ligne, sa position et sa valeur.

```
# Build the lexer
lexer = lex.lex()
data = """
//djhthdh;
int a=5;
while(a>5) do {
  print(a);}
for(i=1;i<=10;i=i+1) {
    i=i+1;
if(a==5) then {
    int a=2;
//djhthdh;
print("")
print("")
print("LEXER")
print("")
print("")
lexer.input(data)
while True:
   tok = lexer.token()
    if not tok:
      break # No more input
    tok.lexpos = lexer_pos_in_line
    lexer_pos_in_line += len(tok.value)
    print(f"{tok.type} at line {tok.lineno}, pos {tok.lexpos}: {tok.value}")
```

Analyse syntaxique avec le Parser:

Cette partie construit l'analyseur syntaxique (`parser`) et l'utilise pour analyser l'entée de l'utilisateur qui est sous forme d'une séquence d'instructions (`data`). Le résultat de l'analyse est imprimé. Si l'analyse syntaxique est réussie, `result` contient une représentation arborescente de la structure de la séquence d'instructions 'data' représentant le processus shift/reduce que l'analyseur syntaxique(parser) avec laquelle il s'est assuré que 'data' est conforme à la grammaire.

```
print("La sequence d'instructions est lexicalement correcte")
421
      print("Tous les lexemes sont recconnus par le LEXER")
      print("")
      print("")
      print("PARSER")
      print("")
      print("")
      # Build the parser
      parser = yacc.yacc()
      result = parser.parse(data,lexer=lexer)
      print(result)
      print("")
      print("")
      print("La sequence d'instructions est syntaxiquement correcte")
      print("Tous les instructionss sont reconnus par le PARSER")
      print("")
      print("")
```

Conclusion:

En résumé, ce code combine un **analyseur lexical (lexer)** et un **analyseur syntaxique (parser)** pour traiter un code source en vérifiant sa validité syntaxique tout en respectant la **grammaire EBNF**. En cas d'erreur, des messages détaillés sont affichés, indiquant la nature et l'emplacement des erreurs.